Transformação de dados com dplyr : : FOLHA DE REFERÊNCIA

Funções dyplr funcionam com canalização (pipes) e esperam dados organizados (tidy). Em dados organizados temos:

Cada variável está em sua própria coluna

&

Cada observação, está em sua própria linha

Pipes

x %>% f(y)
É o mesmo que f(x, y)

Resumindo Observações

Aplica funções de resumo em colunas para criar uma nova tabela estatística resumida. Funções de resumo recebem vetores como entrada e retornam um único valor (vide verso).

função de resumo →

summarise(.data, …)
Computa tabela de resumo.
summarise(mtcars, avg = mean(mpg))

count(.data, …, wt = NULL, sort = FALSE, name = NULL) Conta número de linhas em cada grupo definidos com suas variáveis...Também tally().
count(mtcars, cyl)

Agrupando Observações

Use group_by (.data, …, .add = FALSE, .drop = TRUE) para criar uma cópia da tabela agrupada por colunas ... As funções do dplyr irão manipular cada grupo separadamente e combinar os resultados.

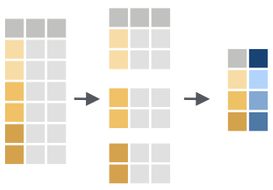

```
mtcars %>%
  group_by(cyl) %>%
  summarise(avg = mean(mpg))
```

Use rowwise(.data, …) para agrupar dados em linhas individuaisFunções do dyplr irão computar os resultados para cada linha. Também aplica funções em colunas de listas. Veja a folha de referência do tidyr sobre o fluxo de colunas de listas.

```
starwars %>%
  rowwise() %>%
  mutate(film_count = length(films))
```

ungroup(x, …) Retorna uma cópia desagrupada da tabela.
ungroup(g_mtcars)

Manipulando Observações

EXTRAÇÃO DE OBSERVAÇÕES

Funções de linhas retornam um subconjunto de linhas como uma nova tabela.

filter(.data, …, .preserve = FALSE) Extrai linhas que satisfazem o critério lógico.
filter(mtcars, mpg > 20)

distinct(.data, …, .keep_all = FALSE) Remove linhas com valores duplicados.
distinct(mtcars, gear)

slice(.data, …, .preserve = FALSE) Seleciona linhas pela posição.
slice(mtcars, 10:15)

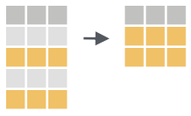

slice_sample(.data, …, n, prop, weight_by = NULL, replace = FALSE) Randomicamente seleciona linhas. Use n para selecionar o número de linhas e prop para selecionar um percentual das linhas.
slice_sample(mtcars, n = 5, replace = TRUE)

slice_min(.data, order_by, …, n, prop, with_ties = TRUE) and slice_max() Seleciona linhas com valores minímo e máximo.
slice_min(mtcars, mpg, prop = 0.25)

slice_head(.data, …, n, prop) and slice_tail() Seleciona as primeiras or últimas linhas.
slice_head(mtcars, n = 5)

Operadores Lógicos e Booleanos para usar com filter()

==	<	<=	is.na()	%in%	|	xor()
!=	>	>=	!is.na()	!	&	

Veja ?base::Logic e ?Comparison para ajuda.

ARRANJAR OBSERVAÇÕES

arrange(.data, …, .by_group = FALSE) Ordena linhas por valores de uma coluna ou colunas (menor para maior), use com desc() para ordenar de maior para menor.
arrange(mtcars, mpg)
arrange(mtcars, desc(mpg))

ADICIONAR OBSERVAÇÕES

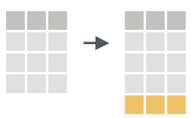

add_row(.data, …, .before = NULL, .after = NULL) Adiciona uma ou mais linhas em uma tabela.
add_row(cars, speed = 1, dist = 1)

Manipulando Variáveis

EXTRAÇÃO DE VARIÁVEIS

Funções de colunas retornam um conjunto de colunas como um novo vetor ou tabela.

pull(.data, var = -1, name = NULL, …) Extrai valores da coluna como um vetor, por nome ou índice.
pull(mtcars, wt)

select(.data, …) Extrai colunas como uma tabela.
select(mtcars, mpg, wt)

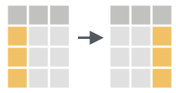

relocate(.data, …, .before = NULL, .after = NULL) Move colunas para uma nova posição.
relocate(mtcars, mpg, cyl, .after = last_col())

Use estes complementos com select() e across()
e.g. select(mtcars, mpg:cyl)

contains(match)	num_range(prefix, range)	:, e.g. mpg:cyl
ends_with(match)	all_of(x)/any_of(x, …, vars)	-, e.g, -gear
starts_with(match)	matches(match)	everything()

MANIPULAR VÁRIAS VARIÁVEIS DE UMA VEZ

across(.cols, .funs, …, .names = NULL) Resume ou alterar múltiplas colunas da mesma maneira.
summarise(mtcars, across(everything(), mean))

c_across(.cols) Computa através das colunas os dados linha a linha.
transmute(rowwise(UKgas), total = sum(c_across(1:2)))

CRIANDO NOVAS VARIÁVEIS

Aplica funções vetorizadas em colunas. Funções vetorizadas recebem vetores como entradas e retornam vetores do mesmo tamanho como saída (vide verso).

Função vetorizada →

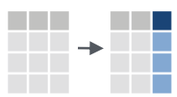

mutate(.data, …, .keep = "all", .before = NULL, .after = NULL) Computa nova(s) coluna(s). Veja também add_column(), add_count(), e add_tally().
mutate(mtcars, gpm = 1 / mpg)

transmute(.data, …) Computa nova(s) coluna(s) e descarta as demais.
transmute(mtcars, gpm = 1 / mpg)

rename(.data, …) Renomeia colunas. Use rename_with() para renomear usando uma função.
rename(cars, distance = dist)

Funções Vetorizadas

PARA USAR COM MUTATE ()

mutate() e transmute() aplicam funções vetorizadas em colunas para criar novas colunas. Funções vetorizadas recebem vetores como argumento de entrada e retornar vetores de mesmo tamanho como saída.

Função vetorizada

DESLOCAMENTO
dplyr::lag() – desloca elementos em 11
dplyr::lead() – desloca elementos em -1

AGREGAÇÃO ACUMULADA
dplyr::cumall() – acumulado de all()
dplyr::cumany() – acumulado de any()
cummax() – acumulado de max()
dplyr::cummean() – acumulado de mean()
cummin() – acumulado de min()
cumprod() – acumulado de prod()
cumsum() – acumulado de sum()

RANQUEAMENTO
dplyr::cume_dist() – proporção de todos valores <=
dplyr::dense_rank() – ranq. sem brechas
dplyr::min_rank() – ranq. com empates = min
dplyr::ntile() – intervalões em n intervalos
dplyr::percent_rank() - min_rank escalado até [0,1]
dplyr::row_number() – ranq. empates = “primeiro”

MATEMÁTICA
+, - , *, /, ^, %/%, %% - oper. aritiméticas
log(), log2(), log10() - logs
<, <=, >, >=, !=, == - comparações lógicas
dplyr::between() - x >= esquerda & x <= direita
dplyr::near() - == seguro para números com pontos flutuantes

MISCELÂNIA
dplyr::case_when() - if_else() de vários casos

```
starwars %>%
  mutate(type = case_when(
    height > 200 | mass > 200 ~ "large",
    species == "Droid"        ~ "robot",
    TRUE                      ~ "other")
  )
```

dplyr::coalesce() – primero valor não-NA por elemento através de um conjunto de vetores
dplyr::if_else() - if() + else() elemento por elemento
dplyr::na_if() – altera um valores específico para NA
pmax() - max() elemento por elemento
pmin() - min() elemento por elemento

Funções de Resumo

PARA USAR COM SUMMARISE ()

summarise() aplica funções de resumo em colunas para criar uma nova tabela. Funções de resumo recebem vetores como entrada e retornam um valor único na saída.

Função de resumo

CONTAGEM
dplyr::n() – número de valores/linhas
dplyr::n_distinct() - # de valores únicos
sum(!is.na()) - # de não-NA’s

POSIÇÃO
mean() - média, também mean(!is.na())
median() - mediana

LÓGICA
mean() – proporção de verdadeiros (TRUE)
sum() - # de verdadeiros (TRUE)

ORDEM
dplyr::first() – primeiro valor
dplyr::last() – último valor
dplyr::nth() – valor na enésima posição do vetor

RANQUEAMENTO
quantile() - enésimo quartil
min() – valor mínimo
max() – valor máximo

DISPERSÃO
IQR() – distância inter-quartil
mad() – desvio absoluto médio
sd() – desvio padrão
var() - variância

Nome de Linhas

Dados organizados (tidy) não usam nomes de linhas (que contém uma variável fora das colunas). Para trabalhar com este nomes, mova para uma coluna.

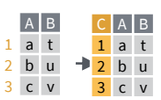

tibble::rownames_to_column()
Move nomes de linhas para coluna.
a <- rownames_to_column(mtcars, var = "C")

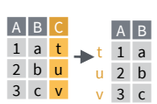

tibble::column_to_rownames()
Move coluna como nome das linhas.
column_to_rownames(a, var = "C")

Veja também tibble::has_rownames() e tibble::remove_rownames().

Combinando Tabelas

JUNTANDO VARIÁVEIS

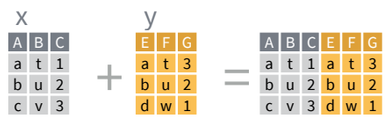

bind_cols(…, .name_repair) Retorna tabelas colocadas lado a lado como um tabela única. Comprimento das colunas devem ser iguais. Colunas não serão combinadas por id (para isso veja Dados Relacionais abaixo), então certifique-se que ambas as tabelas estão ordenadas como você deseja antes de uni-las.

JUNTANDO OBSERVAÇÕES

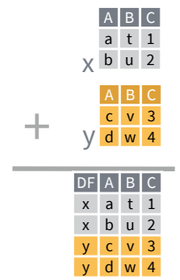

bind_rows(…, .id = NULL) Retorna tabelas uma em cima da outra como uma tabela única. Defina .id para nome de coluna para incluir uma coluna com a tabela original (conforme figura ao lado).

RELATIONAL DATA

Use uma "União Transformadora" para unir uma tabela com colunas de outra, combinando valores de linhas correspondentes. Cada união (join) retem uma combinação diferente de valores das tabelas.

left_join(x, y, by = NULL, copy = FALSE, suffix = c(".x", ".y"), …, keep = FALSE, na_matched = "na") Une valores iguais de y em x.

right_join(x, y, by = NULL, copy = FALSE, suffix = c(".x", ".y"), …, keep = FALSE, na_matches = "na") Une valores iguais de x em y.

inner_join(x, y, by = NULL, copy = FALSE, suffix = c(".x", ".y"), …, keep = FALSE, na_matches = "na") Une todos os dados. Retem somente linhas em comum.

full_join(x, y, by = NULL, copy = FALSE, suffix = c(".x", ".y"), …, keep = FALSE, na_matches = "na") Ene dados, retem todos os valores e todas as linhas.

COMBINANDO COLUNAS PARA UNIÕES

Use by = c("col1", "col2", …) para definir uma ou mais colunas de combinação.
left_join(x, y, by = "A")

Use um vetor, by = c("col1" = "col2"), para combinar colunas com nomes diferentes em cada tabela.
left_join(x, y, by = c("C" = "D"))

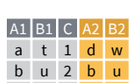

Use suffix para definir o sufixo para colunas não combinadas que tem o mesmo nome em tabelas diferentes.
left_join(x, y, by = c("C" = "D"), suffix = c("1", "2"))

Use uma "União de Filtro" para filtrar uma tabela conforme linhas de uma outra tabela.

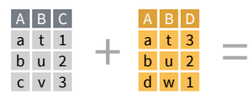

semi_join(x, y, by = NULL, copy = FALSE, …, na_matches = "na") Retorna linhas de x que estão presentes em y. Use para ver o que será incluído em uma união.

anti_join(x, y, by = NULL, copy = FALSE, …, na_matches = "na") Retorna linhas de x que não estão presentes em y. Use para ver o que NÃO será incluído em uma união..

Use uma "União de Aninhamento" para inserir uma tabela em um data frame.

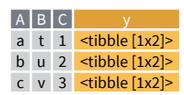

nest_join(x, y, by = NULL, copy = FALSE, keep = FALSE, name = NULL, …) Une dados, aninhando combinações de y em uma nova coluna de um data frame.

OPERAÇÕES DE DEFINIÇÃO

intersect(x, y, …)
Linhas que aparecem em x e y.

setdiff(x, y, …)
Linhas que aparecem em x mas não em y.

union(x, y, …)
Linhas que aparecem em x ou y. (Remove dupliadas). union_all() mantém duplicadas.

Use setequal() para testar se dois conjunto de dados contém as mesmas linhas (em qualquer ordem).